Used Car Price Prediction

فاز ۳ پروژه: Feature Engineering & Feature Encoding

🧠 سناریو پروژه

در فاز دوم، دیتاست پاک‌سازی شد و نسخه نهایی آن با نام cars_clean.csv ذخیره گردید.

اکنون مدیر پروژه از شما می‌خواهد قبل از ساخت مدلMachine Learning ، ویژگی‌های موجود را برای آموزش مدل آماده کنید.

بسیاری از ستون‌های موجود در دیتاست به صورت متنی هستند یا چندین اطلاعات مختلف را در یک ستون ذخیره کرده‌اند. مدل‌های Machine Learning نمی‌توانند این اطلاعات را به صورت مستقیم پردازش کنند؛ بنابراین لازم است ویژگی‌های جدید استخراج شده و داده‌های متنی به مقادیر عددی تبدیل شوند.

هدف این فاز، ساخت یک دیتاست استاندارد و آماده برای ورود به مرحله آموزش مدل است.

📦 ساختار پروژه

```
project/

|
├── data/
|       ├── cars.csv
|       ├── cars_clean.csv
|       └── cars_features.csv
|
├── notebooks/
|       └── 03_feature_engineering.ipynb
|
├── reports/
|       └── phase3_report.pdf
|
└── README.md
```

📊 **توضیح فایل‌ها**

data/cars_clean.csv

دیتاست پاک‌سازی‌شده (خروجی فاز دوم)

---

data/cars_features.csv

دیتاست نهایی پس از انجام Feature Engineering

---

notebooks/03_feature_engineering.ipynb

تمام مراحل استخراج ویژگی، Encoding و آماده‌سازی نهایی داده‌ها در این فایل انجام می‌شود.

---

reports/phase3_report.pdf

گزارش کامل Feature Engineering

📌 **تسک‌های فاز سوم**

✅ **تسک 1 : بررسی اولیه Featureها**

فایل **cars_clean.csv** را بارگذاری کنید.

موارد زیر را بررسی نمایید:

- تعداد ستون‌ها
- ستون‌های عددی
- ستون‌های متنی
- ستون Target

در پایان به سوال زیر پاسخ دهید:

کدام ستون‌ها به صورت مستقیم قابل استفاده در مدل Machine Learning نیستند؟ دلیل خود را بنویسید.

✅ **تسک 2 : Feature Extraction از ستون Engine**

(پیشنهاد میشود قبل از شروع این پروژه در مورد One Hot Encoding & Label Encoding تحقیق کنید، منبع پیشنهادی :

/https://www.geeksforgeeks.org/machine-learning/one-hot-encoding-vs-label-encoding)

ستون **engine** شامل اطلاعات متنوعی است.

نمونه‌ها:

300HP 3.7L V6

2.0L I4 Turbo

Electric Motor

V6

از این ستون ویژگی‌های زیر را استخراج کنید.

- Horse Power
- Engine Size
- Engine Type

ستون‌های جدید زیر را ایجاد کنید:

horsepower

engine_size

engine_type

در پایان چند سطر اول دیتاست را نمایش دهید و صحت استخراج ویژگی‌ها را بررسی کنید.

*(در صورتی که هیچ ایده ای برای انجام این بخش ندارید به فایل hint برای راهنمایی بیشتر مراجعه کنید)

✅ تسک 3 : استانداردسازی ستون Transmission

مقادیر ستون Transmission یکدست نیستند.

نمونه‌ها:

Automatic

8-Speed Automatic

A/T

6-Speed A/T

6-Speed M/T

Transmission w/Dual Shift Mode

CVT

یک ستون جدید با نام

transmission_clean

ایجاد کنید.

تمام مقادیر را در یکی از گروه‌های زیر قرار دهید.

- Automatic
- Manual
- CVT
- Dual Shift
- Other

در پایان تعداد خودروهای هر گروه را نمایش دهید.

*(در صورتی که هیچ ایده ای برای انجام این بخش ندارید به فایل hint برای راهنمایی بیشتر مراجعه کنید)

✅ **تسک 4 : Encoding داده‌های متنی**

ستون‌های زیر را بررسی کنید.

- brand
- fuel_type
- accident
- clean_title
- engine_type
- transmission_clean

برای هر ستون مشخص کنید:

- از Label Encoding استفاده می‌کنید یاOne-Hot Encoding ؟
- دلیل انتخاب روش خود را توضیح دهید .

سپس عملیات Encoding را انجام دهید.

*(در صورتی که هیچ ایده ای برای انجام این بخش ندارید به فایل hint برای راهنمایی بیشتر مراجعه کنید)

✅ **تسک 5 : حذف ستون‌های غیرضروری**

پس از استخراج ویژگی‌ها، بررسی کنید کدام ستون‌ها دیگر موردنیاز نیستند.

در صورت لزوم ستون‌های زیر را حذف کنید.

- engine
- transmission

دلیل حذف هر ستون را نیز توضیح دهید.

✅ **تسک 6 : بررسی دیتاست نهایی**

پس از پایان مراحل Feature Engineering موارد زیر را بررسی کنید.

- تعداد ستون‌ها
- نوع داده ستون‌ها
- وجود مقدار گمشده
- نمایش پنج سطر اول دیتاست

در پایان به سوال زیر پاسخ دهید.

آیا دیتاست اکنون برای آموزش مدل Machine Learning آماده است؟ دلیل خود را بنویسید.

✅ **تسک 7 : تحلیل ویژگی‌ها (Feature Selection)**

در این مرحله، ارتباط بین **ویژگی‌های اصلی عددی** را بررسی کنید.

توجه:
برای جلوگیری از شلوغ شدن نمودار، از تمامی ستون‌های دیتاست استفاده نکنید. فقط ویژگی‌های اصلی زیر را برای تحلیل انتخاب کنید.

ویژگی‌های پیشنهادی:

- price

- milage
- model_year
- horsepower
- engine_size

در صورتی که ستون‌های accident و clean_title را با Label Encoding به عدد تبدیل کرده‌اید، می‌توانید آن‌ها را نیز به تحلیل اضافه کنید.

موارد موردنیاز

- ماتریس همبستگی (Correlation Matrix) را محاسبه کنید .
- Heatmapرا رسم کنید .
- مشخص کنید کدام ویژگی بیشترین ارتباط را با ستون **price**دارد .
- بررسی کنید آیا بین دو ویژگی دیگر نیز همبستگی بالایی وجود دارد یا خیر .
- در پایان، تحلیل کوتاهی (حداقل ۳ خط) درباره نتایج بنویسید

✅ **تسک 8 : ذخیره دیتاست نهایی**

دیتاست نهایی را با نام

cars_features.csv

ذخیره کنید.

📌 **خروجی مورد انتظار**

در پایان فاز سوم، دانشجو باید فایل‌های زیر را تحویل دهد.

Notebook

03_feature_engineering.ipynb

شامل:

- کدها
- توضیحات
- تحلیل‌ها

دیتاست

cars_features.csv

گزارش PDF

phase3_report.pdf

حداقل شامل:

- ویژگی‌های استخراج‌شده
- مراحل Encoding
- دلیل انتخاب روش Encoding
- ویژگی‌های حذف‌شده
- Heatmapهمبستگی
- تحلیل Feature Selection
- نتیجه‌گیری نهایی

README

توضیح کوتاهی درباره تغییرات انجام‌شده روی دیتاست.

💡 **نکات مهم**

- برای هر ویژگی جدید، دلیل استخراج آن را توضیح دهید .
- قبل از حذف هر ستون، اطمینان حاصل کنید که اطلاعات موردنیاز آن در ستون‌های جدید ذخیره شده است .

- روش Encoding انتخاب‌شده برای هر ستون را مستند کنید .
- تحلیل Heatmap و Correlation بخشی از ارزیابی پروژه است و صرفاً رسم نمودار کافی نیست .
- در پایان این فاز، دیتاست باید تا حد امکان شامل ویژگی‌های عددی و آماده برای ورود به مرحله آموزش مدل باشد.